Plataforma Analítica de Riesgo Financiero y Detección de Fraude

Prueba Técnica · Data Scientist Senior · Hitss Colombia / Claro Colombia

Alejandro

2026-11-11

1. Entendimiento del problema

Una organización bancaria quiere evolucionar su plataforma analítica hacia modelos predictivos y un agente inteligente IA. Se pide entrenar y evaluar **dos modelos** sobre fuentes de datos heterogéneas (cloud + on-prem):

- **Modelo de riesgo financiero:** evalúa y actualiza continuamente el nivel de riesgo de un cliente.
- **Modelo de fraude/anomalías:** identifica comportamientos transaccionales atípicos.

El alcance no es solo el modelo: cubre **todo el ciclo de vida** (datos, entrenamiento, despliegue, monitoreo, consumo) con buenas prácticas de industria.

2. Arquitectura de referencia

Capas end-to-end

- **Fuentes:** BD core (on-prem) + data lake (cloud) + eventos transaccionales.
- **Ingesta:** Spark/Airflow (batch) + Kafka/Spark Streaming (real-time).
- **Entrenamiento:** pipeline reproducible con feature engineering y validación.
- **Registro:** MLflow Model Registry (versionado y stages).
- **Serving:** FastAPI (online) + Spark (batch), sobre Kubernetes.
- **Consumo:** API gateway gobernada para el agente IA y aplicaciones.
- **Monitoreo:** Evidently AI + Great Expectations + Prometheus/Grafana.

Decisiones clave

Decisión	Elección	Justificación
Orquestación	Airflow + Spark + Kafka	Conviven batch (riesgo) y streaming (fraude)
Feature store	Feast (online/offline)	Consistencia train/serve
Registro	MLflow	Versionado y promoción gobernada
Serving	FastAPI + Spark sobre K8s	Latencia <100ms y batch escalable
Monitoreo	Evidently + GE + Prometheus	Drift, calidad y operación
Explainability	SHAP + model cards	Exigencia regulatoria bancaria

3. Modelo de riesgo financiero

- **Tipo:** clasificación supervisada (probabilidad de default) con score continuo.
- **Target:** default a 90+ días en ventana 6-12 meses.
- **Algoritmo:** Gradient Boosting (LightGBM/XGBoost) + baseline de regresión logística interpretable.
- **Variables:** sociodemográficas, producto, comportamiento de pago, transaccional, buró, macro.
- **Feature engineering:** agregaciones temporales (3/6/12m), ratios, target encoding out-of-fold.
- **Evaluación:** AUC ≥ 0.80, KS ≥ 0.35, Gini ≥ 0.55, precision@k, calibración, PSI < 0.1.
- **Validación:** CV temporal (walk-forward) para evitar fuga de futuro.
- **Explicabilidad:** SHAP global y local para el agente IA y analistas.
- **Frecuencia:** retraining mensual + trigger por drift; scoring batch y on-demand.

4. Modelo de fraude / anomalías

- **Naturaleza:** etiquetas escasas y desbalanceadas, baja latencia requerida.
- **Enfoque híbrido:** Isolation Forest/Autoencoder (no supervisado) + XGBoost (supervisado) + reglas, con score combinado calibrado por costo.
- **Variables:** monto/frecuencia, desviación vs perfil, geografía, dispositivo, red, temporal.
- **Evaluación:** precision alta (pocos FP), recall balanceado, PR-AUC, FPR < 5%, latencia P95 < 100ms.
- **Feedback loop:** analista confirma/descarta → ground truth → reentrenamiento semanal.
- **Resiliencia:** fallback a reglas si el score online falla (nunca bloquear por fallo técnico).

5. Ciclo de vida (MLOps)

- **Estados:** Registered → Staging → Production → Archived (MLflow).
- **Versionado:** semver + run ID + hash de datos; artefactos inmutables.
- **Promoción con gates:** tests → shadow deployment → validación → aprobación humana.
- **Estrategias:** shadow, canary, blue/green, champion/challenger.
- **CI/CD:** push → lint/test → training → validación → registro → despliegue.
- **Gobierno:** aprobaciones por rol, model cards, ADR, trazabilidad completa.
- **Manejo del cambio:** retraining por drift, canales de feedback, revisión trimestral.

6. Monitoreo y control

Dimensión	Métrica	Herramienta
Data drift	PSI / KS por feature	Evidently AI
Concept drift	AUC / precision degradados	Evidently + negocio
Calidad de datos	nulos, rangos, esquema	Great Expectations
Operativo	latencia, throughput, errores	Prometheus/Grafana

- **Umbrales PSI:** < 0.1 OK, 0.1-0.25 alerta, > 0.25 crítico.
- **Respuesta:** drift → retraining/rollback; latencia → escalado HPA.
- **Anticipación:** monitoreo de anomalías en features, pruebas de estrés, runbooks.

7. Entrega operativa y consumo

- **Riesgo:** batch (cartera) + API on-demand.

- **Fraude:** API real-time.
- **API:** REST versionada (/v1), OAuth2/mTLS, rate-limit, contrato OpenAPI.
- **Agente IA:** consume scores + explicaciones SHAP, traduce a lenguaje natural, recomienda acciones; sin decidir solo en temas sensibles.
- **Acceso:** gateway con scopes, cuotas y auditoría por consumidor.

8. Supuestos, alternativas y riesgos

Supuestos

- Datos transaccionales, producto, sociodemográficos y buró con ≥ 18-24 meses de histórico.
- Infra cloud (K8s + data lake) y BD core on-prem integrables.
- Etiquetas de fraude (con retardo) y defaults históricos disponibles.
- Cumplimiento normativo (habeas data, explicabilidad, auditoría).

Alternativas descartadas

Alternativa	Por qué
Deep learning para tabular	GBM similar desempeño, menos costo, más explicable
Todo on-prem / todo cloud	Se adopta híbrido por dependencias
Sin feature store	Riesgo de train/serve skew
Modelo único para ambos problemas	Targets, latencia y métricas distintas
AutoML puro	Menos control y trazabilidad

Riesgos aceptados

- Etiquetas de fraude tardías → enfoque híbrido + feedback loop.
- Falsos positivos → umbral calibrado + explicación.
- Data drift → monitoreo PSI/KS + retraining.
- Complejidad MLOps → automatización progresiva (MVP primero).

9. Métricas y valor

- **Técnicas:** AUC/KS/Gini (riesgo), precision/recall/PR-AUC/FPR (fraude).
- **Negocio:** pérdidas por fraude evitadas, reducción de mora, menos falsos positivos.
- **Valor:** mejores decisiones de otorgamiento, menos pérdida, mejor experiencia, capacidad de escalar a nuevos casos de uso.

10. Plan y mejoras

- **Entregables:** repo de código, documentación, pipeline, API, monitoreo, mockups.
- **Tiempo MVP:** ~10-12 semanas (ingesta 2s, riesgo 2-3s, fraude 3-4s, API 1-2s, monitoreo 2s).
- **Aceleradores:** feature store desde el día 1, plantillas de pipeline, shadow deployment, auto-retraining por drift.

Presión para salir antes a producción

1. Priorizar riesgo primero; fraude en shadow mode.
2. MVP con guardarraíles (modelo simple + monitoreo básico).
3. Reducir alcance, no el gobierno mínimo.
4. Comunicar riesgos explícitamente.

5. Nunca salir sin feature store mínimo, rollback y alerta de drift.

11. Mockups de salidas

API riesgo:

```
{ "cliente_id": "CLI-1000231", "score": 0.18, "bucket": "bajo",
  "explicacion": { "top_factores": [ ... ] } }
```

Alerta fraude:

```
{ "transaccion_id": "TX-9988123", "score_anomalia": 0.93,
  "decision": "REVISAR", "razones": ["monto 8x mediana", ...] }
```

Dashboard monitoreo: PSI por feature, performance de fraude, latencia y throughput.

12. Mejoras futuras

- AutoML guiado, explicaciones LLM en lenguaje natural.
- Detección de fraude en grafos (anillos).
- Scoring de riesgo en streaming.
- Online learning con monitoreo reforzado.
- Data contracts para robustecer la ingesta.

Conclusión

La solución es **pragmática y escalable**: GBM tabular con feature store y MLflow, un enfoque híbrido para fraude con feedback loop, monitoreo continuo de drift y una API gobernada que alimenta al agente IA. El valor no está solo en predecir, sino en **explicar y hacer accionable** el resultado para el negocio.